

음악 소스 분리 모델을 활용한 Wave-U-Net 기반 자동 음악 믹싱 시스템

윤진성*, 심영준*, 서영주**

Automatic Music Mixing Using Music Source Separation Models and Wave-U-Net

Jinsung Yoon*, Youngjun Sim* and Young-Joo Suh**

요 약

음악 믹싱은 개별 트랙 형태로 악기를 녹음하고, 이를 전문가의 지식을 이용하여 적절히 다듬어 섞는 과정을 뜻한다. 최근 몇 년 동안 딥러닝을 활용한 자동 음악 믹싱이 연구되었지만, 개별 트랙 녹음과 믹싱이 되지 않은 드라이한 녹음 데이터의 부족은 이러한 모델의 성능을 제한시켰다. 본 연구에서는 음악 소스 분리 모델을 이용하여 개별 트랙 녹음을 추출하고 무작위로 볼륨이 조절된 녹음을 생성하여 데이터 부족 문제를 해결한다. 이후 Wave-U-Net 기반의 자동 음악 믹싱 모델을 학습하여 자동 음악 믹싱 시스템을 설계한다.

Abstract

Music mixing refers to the process of recording individual tracks of instruments and refining them using expert knowledge to blend them appropriately. In recent years, there has been research into automated music mixing utilizing deep learning; however, the lack of dry recording data with individual track recordings and mixing has limited the performance of such models. In this study, we address the data scarcity issue by employing music source separation models to extract individual track recordings and generate recordings with randomly adjusted volumes. Subsequently, we train a Wave-U-Net-based automatic music mixing model to design an automated music mixing system.

Key words

automatic music mixing, music source separation, Wave-U-Net, acoustic AI, deep learning

* 포항공과대학교 인공지능대학원, truestar2001@postech.ac.kr, youngjunsim@postech.ac.kr

** 포항공과대학교 인공지능대학원, yjsuh@postech.ac.kr(교신저자)

※ 이 논문은 2024년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원(RS-2019-II191906)과 2024년도 정부(교육부)의 재원으로 한국연구재단의 지원(No.2022R1A6A1A03052954)과 2024년도 정부(과학기술정보통신부)의 재원으로 한국지능정보사회진흥원의 지원(2024년 지역특화형 초거대 AI 클라우드 팜 실증 및 확산 환경 조성)을 받아 수행된 연구이며, 「과학기술정보통신부 방송통신발전기금」을 지원받아 정보통신산업진흥원(D1014-24-1009, 철도차량 가용성 향상을 위한 AI 융합형 통합정비 공정 메타버스 플랫폼 개발)의 지원을 받아 수행된 연구이나 과학기술정보통신부의 공식의견과 다를 수 있음.

I. 서론

음악 믹싱은 여러 개별 악기 트랙을 적절히 조정하여 하나의 곡으로 완성하는 과정으로, 볼륨, 주파수, 공간감 등을 조절해 청각적으로 균형 잡힌 사운드를 구현하는 작업이다. 특히 볼륨 조절은 트랙 간 볼륨의 상대적 크기를 조정해 특정 악기를 강조하거나 최적의 밸런스를 맞추는 믹싱의 핵심 작업이다.

최근에는 딥러닝 기술의 발달로 자동 음악 믹싱이 활발히 연구되고 있으며, 특히 볼륨 조절 작업에서 Wave-U-Net[1] 기반 모델들의 가능성이 입증되었다. 그러나 믹싱된 음악에서 분리된 개별 악기 트랙 데이터의 부족과, 믹싱 되지 않은 개별 트랙 악기 데이터의 부재는 자동 음악 믹싱 모델의 학습을 능력을 저하시키고 성능의 제약을 야기한다.

본 연구에서는 음악 소스 분리 모델 Hybrid Transformer Demucs(HT Demucs)[2]을 활용하여 믹싱된 음악에서 분리된 개별 트랙을 추출하고, 각 분리된 트랙의 볼륨을 무작위로 조정하여 자동 음악 믹싱을 위한 데이터셋을 생성한다. 이를 통해 데이터 부족 문제를 극복하고, Wave-U-Net 구조를 활용하여 자동으로 볼륨 밸런스를 조절하는 음악 믹싱 시스템을 제안한다.

II. 자동 음악 믹싱 시스템




그림 1. 자동 음악 믹싱 시스템 모식도

Fig. 1. Automatic music mixing system architecture

제안된 자동 음악 믹싱 시스템의 전체 구조는 그림 1과 같다. HT Demucs와 무작위 볼륨 조절을 통해 딥러닝 기반 음악 믹싱 모델을 위한 훈련-타겟 데이터 쌍을 생성한다. 이후 Wave-U-Net 구조의 음악 믹싱 모델을 학습하여 믹싱 전의 개별 트랙들의 볼륨을 조정해 최적의 믹싱된 음악으로 변환한다.

2.1 타겟 데이터셋 생성

개별 악기 트랙 녹음이 존재하지 않는 무작위 음악 데이터를 HT Demucs에 통과시켜 분리된 개별 악기 트랙을 추출한다. HT Demucs는 Wave-U-Net 구조에서 가장 깊은 층을 트랜스포머 층으로 교체하고 트랙 혼합 녹음 입력을 높은 품질의 4개의 개별 악기 트랙 녹음(베이스, 드럼, 보컬, 그 외)으로 분리하여 출력하는 딥러닝 기반 음악 소스 분리 모델이다. 개별 악기 트랙이 없는 음악 데이터셋 GTZ AN[3]의 음악 300곡을 HT Demucs를 통해 개별 악기 트랙을 생성하고, 개별 악기 트랙이 있는 MUSDB18[4] 데이터셋의 음악 100곡과 병합하여 총 400곡의 타겟 데이터셋을 구축한다.

2.2 훈련 데이터셋 생성

$$scaling = \begin{cases} 1/(4-6x) & 0 \leq x < 0.5 \\ 1+6(x-0.5) & 0.5 \leq x < 1 \end{cases} \quad (1)$$

타겟 데이터 셋의 개별 악기 트랙의 볼륨을 인위적으로 조정하여 믹싱 되지 않은 훈련 데이터셋을 생성한다. 식 (1)은 균등분포에서 샘플링된 x 를 통해 0.25~4 사이의 무작위 볼륨 조절 인자를 생성하는 식을 나타낸다. 0.25~4 사이의 무작위 값을 볼륨 조절 인자로 사용하면 1 이상의 인자가 추출될 확률이 더 높아지고, 결과적으로 볼륨을 낮출 확률보다 키울 확률이 높아지게 된다. 식 (1)을 통해 0.25~1과 1~4의 볼륨 조절 인자가 추출될 확률이 같아지도록 하였다. 각 트랙에 해당 조절 요소를 곱하여 볼륨이 조절된 새로운 악기 트랙을 생성한다. 이를 통해 자동 음악 믹싱 모델을 위한 훈련-타겟 데이터 쌍을 구축한다.

2.3 음악 믹싱

구축한 데이터셋을 이용해 믹싱 되지 않은 개별 악기 트랙을 믹싱된 개별 악기 트랙으로 변환하는 모델을 학습시킨다. 음악 믹싱 모델은 U-Net 구조를 음성 데이터에 적용될 수 있도록 변형한 Wave-U-Net을 사용한다.

일반적인 U-Net과 달리 1차원 합성곱 신경망(CNN)으로 이루어진 인코더를 사용하여 특징을 추출하고, 선형 보간법과 1차원 합성곱 신경망으로 이루어진 디코더를 사용하여 원본 녹음을 복원한다. 이 과정에서 U-Net과 마찬가지로 인코더와 디코더 사이에는 스킵 연결이 추가된다.

$$L_{total} = L_{spec} + \alpha L_{energy} \quad (2)$$

식 (2)는 모델의 손실 함수를 나타낸다. L_{spec} 은 스펙트로그램으로 변환된 $\hat{y}$ 과 y 의 L_1 거리이며, L_{energy} 는 $\hat{y}$ 과 y 각각의 제곱의 L_1 거리이다. 손실 함수의 가중치인 α 는 1을 사용했다.

III. 실험

표 1은 모델에 따른 볼륨 조절 성능을 평가한 것이다. 비교 모델은 Auto-Encoder를 사용하였다. Randomized는 무작위로 볼륨을 조절한 훈련 데이터셋이며, Wave-U-Net + MSS는 음악 소스 분리 모델을 이용하여 데이터셋을 증강한 후 Wave-U-Net으로 자동 믹싱하는 시스템이다. 각 모델은 4의 배치 크기로 50000 스텝 동안 훈련되었다. 검증 데이터로는 MUSDB18 데이터셋 중 훈련 때 사용되지 않은 50 곡을 사용하였다. 평가 지표로는 평균 음량을 나타내는 LUFS(Loudness Units Full Scale)의 차이를 실제값과 예측값 사이의 오차를 백분율로 나타내주는 지표인 MAPE(Mean Absolute Percentage Error)로 계산한 값을 사용하였다. 또한, 원본 신호와 복원된 신호 간의 왜곡 수준을 나타내는 SDR(Signal-to-Distortion Ratio)를 사용하였다.

Wave-U-Net기반 모델은 Auto-Encoder에 비하여

표 1. 모델 별 LUFS, SDR 점수

Table 1. LUFS, SDR for each model

모델	베이스		드럼		보컬		그 외	
	LUFS ↓	SDR ↑	LUFS ↓	SDR ↑	LUFS ↓	SDR ↑	LUFS ↓	SDR ↑
Radomized	0.265	3.810	0.305	2.076	0.334	1.203	0.261	4.162
Auto-Encoder[5]	0.115	-6.647	0.097	-5.328	0.081	-5.561	0.073	-6.048
Wave-U-Net[1]	0.115	<u>-5.900</u>	0.137	<u>-4.789</u>	0.072	<u>-6.114</u>	<u>0.078</u>	8.112
Wave-U-Net + MSS	0.106	7.480	<u>0.110</u>	6.135	<u>0.076</u>	-6.489	0.080	<u>8.016</u>

모든 악기 트랙에서 전반적으로 높은 점수를 기록하였으며, 음원 소스 분리 모델을 추가하였을 때 베이스와 드럼 트랙에서 큰 폭의 성능 향상을 보였다.

표 2는 손실 함수 설정에 따른 볼륨 조절 성능을 LUFS로 평가한 것이다. L_{time} 은 $\hat{y}$ 과 y 를 스펙트로그램으로 변환하지 않고 L_1 거리를 구한 값이고, L_{spec} 은 $\hat{y}$ 과 y 를 스펙트로그램으로 변환 후 L_1 거리를 구한 값이다. 실험 결과, L_{time} 과 L_{energy} 를 함께 사용하는 것이 ‘베이스’에서, L_{spec} 만 사용하는 것이 ‘드럼’과 ‘보컬’에서, L_{spec} 과 L_{energy} 를 함께 사용하는 것이 ‘그 외’에서 가장 좋은 성능을 나타냈다.

표 2. 손실 함수 설정 별 LUFS 점수

Table 2. LUFS for each loss function setting

손실 함수	베이스	드럼	보컬	그 외
L_{time}	0.116	0.133	0.066	0.170
L_{spec}	0.110	0.116	0.063	0.081
$L_{time} + L_{energy}$	0.108	0.175	0.066	0.079
$L_{spec} + L_{energy}$	0.115	0.137	0.072	0.078

IV. 결 론

본 논문에서는 음악 소스 분리 모델과 Wave-U-Net을 이용하여 자동 음악 믹싱 모델을 제안하였다. 제안된 방법은 개별 악기 트랙이 없는 녹음을 음악 소스 분리 모델을 활용해 개별 악기 트랙 녹음을 생성하여 데이터셋 부족 문제를 해결할 수 있음을 확인한다. 또한 무작위 볼륨 조절을 통해 훈련 데이터셋을 생성하고 이를 이용해 Wave-U-Net 기반 자동 음악 믹싱 시스템을 설계할 수 있음을 보여준다.

참 고 문 헌

- [1] Daniel Stoller, Sebastian Ewert, and Simon Dixon. Wave-u-net: A multi-scale neural network for end-to-end audio source separation, 2018.
- [2] Simon Rouard, Francisco Massa, and Alexandre D'efossez. Hybrid transformers for music source separation. In ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pages 1-5, 2023
- [3] Tzanetakis, G., Cook, P.: Musical genre classification of audio signals. IEEE Trans. Speech Audio Process. 10(5), 293-302 (2002)
- [4] Z. Rafii, A. Liutkus, F.-R. Stöter, S. I. Mimilakis, and R. Bittner, "The MUSDB18 corpus for music separation," Dec. 2017. [Online]. Available: <https://doi.org/10.5281/zenodo.1117372>
- [5] G. E. Hinton, R. R. Salakhutdinov ,Reducing the Dimensionality of Data with Neural Networks. Science 313, 504-507 (2006). DOI: 10. 1126/ science. 1127647